

教AI的陶老师作业训练营04期（1）

一、理论部分

先从机器学习的形式化定义开始说起吧，如果你看到这个概念是一脸懵的话也不用着急，这只是一个入门必备的基础问题，了解这个问题后，有助于你更清楚机器到底是如何完成学习任务的。

以下是机器学习的形式化定义：以P评价计算机程序关于某类任务T上的性能，如果某程序利用经验E使T中的任务获得了性能改善，则称该程序对经验E进行了学习。

"机器学习"形式化定义的三要素：

1. 明确指定的任务T
2. 评价任务性能P的度量指标
3. 用于改善任务性能的经验E

以手写数字识别为例：

- 任务T:识别或预测给定的手写体数字图像类别
- 经验E:已知类别标记的手写体样本图像构成的数据集
- 评价任务性能P的指标:学习系统关于训练样本集的预测正确率

现在你已经知道机器学习的形式化定义是怎样的，也理解了这其中的三要素分别是什么。①请你来尝试回答，在机器利用鸢尾花数据集对鸢尾花进行分类任务的学习过程中，三要素分别对应什么？

通俗来讲，机器学习的过程就是让机器利用已有的经验使得在对应任务上的性能得以提高的过程。也就是说，我们希望机器能够从经验数据中习得一个能够对新样本进行预测的模型。所以，②如何理解“使用机器学习解决问题的目的是为了获得一个复杂函数”这句话？

这里的已有经验，就是通常说的数据集。③请分别以手写数字识别数据集（MNIST）和鸢尾花数据集（iris）为例解释以下相关概念：样本、特征、特征取值、特征向量、特征维数；类别与类别标签、训练集、测试集、验证集。

④“识别或预测给定的手写体数字图像的类别”是一个典型的分类任务，除此之外，机器学习常见的学习任务还包括“回归”、“聚类”、“特征降维”等，请分别举例解释说明。

手写数字识别数据集和鸢尾花数据集都是有类别标签的数据，但有些数据是没有类别标签的(没有标签的数据在平时会更常见到)，比如我们现在有包含了李白所有作品的李白诗集，希望让机器习得李白的创作风格，从而生成李白风格的诗句，而这时的数据集是没有类别标签的。这就涉及到机器学习的不同学习范式。⑤举例解释监督学习、无监督学习（非监督学习）和强化学习分别是怎样的学习范式。

现在你已经知道了机器学习的相关概念，我们回到机器学习过程本身来说。这个过程的理解对你后续的学习至关重要。让机器进行学习前需要先确定三件事：1. 选择一个具有未知参数的模型；2. 定义损失函数；3. 确定优化方法。之后便根据优化方法开始训练模型，直至达到预期标准后，将训练好的模型进行保存，就可以用它对未知数据进行预测了。⑥这个过程具体是怎样的？请举例详尽说明。

对于训练好的模型，⑦经常用“欠拟合”和“过拟合”来对模型性能进行评价，请举例解释这两个概念。

在对模型进行评价时，经常会用到交叉验证的方法，⑧请举例说明如何基于交叉验证进行模型的选择与评价？

这里还有混淆矩阵、ROC曲线、AUC值和P-R曲线的问题，有余力的同学可以自行学习。

本次任务中涉及到MNIST手写数字数据集和iris鸢尾花数据集，是两个适用于学习的经典数据集，同学们从网上找到很多相关资料，建议初学者对这两个数据集进行详细了解，方便后续学习。

二、编程部分

在解决机器学习问题的代码实现中，大多是在 Python 环境中实现。Python 的用法建议直接看官网的说明文档。

在 Python 基础上经常用到的库还包括 NumPy、Pandas、Matplotlib 等。

通过以下几个问题的回答希望能对大家快速入门带来帮助。⑨ NumPy、Pandas、Matplotlib 分别通常用来解决什么样的问题。

这些常用的库里面提供了很多应用于不同问题的方法，这些都有个前提就是对象的类型。⑩ NumPy 和 Pandas 中的数据对应的对象类型是什么。

⑪ NumPy 的 ndarray 和 Python 中的原生数组在使用时都可以使用"[]"，但是由于是两种数据的类型，所以"[]"里面的用法也会不同，具体有哪些区别？⑫ 除此之外，NumPy 的 ndarray 和 Python 中的原生数组还有哪些区别？

在 import numpy as np 执行成功后，说明你可以正常使用 NumPy，并且可以通过 np 来对库进行调用。如果你使用的是anaconda或者pycharm，应该都是已经集成了 NumPy，所以你可以直接使用，如果不能使用的话，可以先下载安装。

⑬ NumPy 的多维数组创建方式分别是如何使用的？

- np.array()
- np.ones()
- np.zeros()
- np.empty()
- np.arange()
- np.ones_like()
- np.zeros_like()
- np.random.random()

⑭ 你发现了么，刚刚生成的数据都是由同一种Python的基本类型构成，是什么？

⑮ np.empty() 生成的是null？NAN？0？还是其他什么？数据怎么来的？

已知有数据： a = np.arange(25).reshape(5, 5)

- ⑯-1 交换2行和3行，交换4列和5列
- ⑯-2 将所有奇数替换为-1
- ⑯-3 将对角线上的值替换为0 要求只通过 [] 的方式来完成上题。

⑰ 使用 Numpy 创建一个 5*5 的矩阵，每行数值都是从 0-4

⑱ 从二维数组 a 2d = np.array([[3,3,3],[4,4,4],[5,5,5]]) 中的每行减去一维数组 b 1d = np.array([1,2,3]) 中相应的值？

上面两题，尝试使用"广播"的方法来实现。

⑲ "广播"到底是什么？有什么规则？

对 Pandas 的调用通常写为 import pandas as pd。

⑳ 已知有一个Python字典存储了3位同学的4门课成绩，课程分别是'C, Java, Python, JS',请创建 DataFrame 类型数据来显示成绩单。字典如下：

```
d = { 'LiYongzhu' : [95, 96, 90, 88], 'LiuQingyuan' : [90, 93, 95, 90], 'GuoYimeng' : [100, 100, 100, 100] }
```

根据 babynames 数据集，解决以下问题：

④-1 分别统计男生和女生的出生人数

④-2 有多少个不重复的名字

④-3 横坐标为年份，纵坐标为数量，男女不同的走势图

本周学习内容涉及了机器学习基础知识以及 NumPy 、 Pandas 、 Matplotlib 的基本使用。希望能对你带来帮助，内容量不小，但相信你可以的，加油💪。