

jieba中文分词工具包

同济子豪兄B站视频专栏: <https://space.bilibili.com/1900783>

子豪兄Python交流QQ群: 1077638784

概述

jieba是一个开源的中文分词库。广泛用于文本分析、词云绘制、关键词提取、自然语言处理等领域。

jieba非常容易上手学习。支持繁体中文分词、支持用户自定义词典。

项目Github地址: <https://github.com/fxsjy/jieba>

安装jieba

```
1 pip install jieba
```

jieba常用函数

精确模式: 把最可能组成词语的词切开, 没有冗余单词。

全模式: 把所有可能组成词语的词切开, 有冗余单词。

搜索引擎模式: 在精确模式的基础上, 对长词再次切分, 适合用于搜索引擎分词。结果和全模式类似。

paddle模式: 使用百度PaddlePaddle飞桨深度学习框架, 调用双向GRU循环神经网络进行分词。

[PaddlePaddle官网](#)

```
1 import jieba
2
3 jieba.lcut('中国科学院大学的大学生')
4 # 精确模式: ['中国科学院', '大学', '的', '大学生']
5
6 jieba.lcut('中国科学院大学的大学生', cut_all=True)
7 # 全模式: ['中国', '中国科学院', '科学', '科学院', '学院', '大学', '的', '大学', '大学生', '学生']
8
9 jieba.lcut_for_search('中国科学院大学的大学生')
10 # 搜索引擎模式: ['中国', '科学', '学院', '科学院', '中国科学院', '大学', '的', '大学', '学生', '大学生']
11
12 # 启动paddle模式, 如果没有安装paddle会自动开始安装, 耗时十秒左右
13 jieba.enable_paddle()
14
15 jieba.lcut('中国科学院大学的大学生', use_paddle=True)
16 # paddle模式: ['中国科学院大学', '的', '大学生']
17
```

```

18 jieba.add_word('科学院大学') # 增加词语“科学院大学”
19 jieba.lcut('中国科学院大学', cut_all=True)
20 # 全模式: ['中国', '中国科学院', '科学', '科学院', '科学院大学', '学院', '大学']

```

对于普通用户，使用精确模式即可。

```
jieba.lcut('中国科学院大学的大学生')
```

jieba背后的“黑科技”算法原理

- 基于前缀词典实现高效的词图扫描，生成句子中汉字所有可能成词情况所构成的有向无环图 (DAG)
- 采用了动态规划查找最大概率路径，找出基于词频的最大切分组合
- 对于未登录词，采用了基于汉字成词能力的 HMM 模型，使用 Viterbi 算法

使用隐马尔可夫、动态规划等概率模型，计算字符之间的关联概率，字符间概率大的就认为是一个词。

使用者不需要知道背后的算法原理，只需要会调用接口即可。

扩展案例

词云可视化：四行Python代码轻松上手到精通

<https://www.bilibili.com/video/BV1i4411W76Z>



词频统计

循环神经网络: <https://www.bilibili.com/video/BV1K7411W7So?p=17>